

Nền tảng Serving LLM nội bộ tích hợp Guardrail & Observability

Nhóm DA#51 — Nguyễn Gia Bảo, Nguyễn Lê Minh
Giai đoạn Tuần 4 (05/10 – 09/10/2026)
Ngày báo cáo 09/10/2026
Repository github.com/Potato1476/vllm-bench @ main (62142f8)

Tóm tắt kết quả

Cả 6 hạng mục nghiệm thu đạt. Hệ thống đạt trần tải 50 req/s toàn cụm, phục vụ 2 mô hình qua Argo CD và 8 Virtual Key cho 7 đề án cùng 1 tài khoản pilot.

1.590 ms p95 tại 50 req/s (ngưỡng 3.000 ms)	99,7228% Availability, cận dưới CI 95%	100% / 0% Chặn tấn công / chặn nhầm	54,3% Tiết kiệm TCO so với Cloud API @10 req/s
---	--	---	--

Tiêu chí	Yêu cầu	Trạng thái	Kết quả đo được
TC1a	p95 latency < 3.000 ms tại 50 req/s toàn cụm	ĐẠT	1.590 ms, dư 47% ngân sách latency
TC1b	Availability toàn cụm ≥ 99,5%	ĐẠT	99,7228% (cận dưới 95% CI, 34.354 probe), không có lỗi 5xx
TC2	Tiết kiệm chi phí ≥ 30% so với Cloud API	ĐẠT	2 báo cáo FinOps; chi phí AWS thực tế 01/09–06/10 là \$86,79; tiết kiệm 49,4% – 54,3% tại 10 req/s
TC3	Chặn tấn công ≥ 95%, chặn nhầm ≤ 2%	ĐẠT	Chặn 100%, chặn nhầm 0% trên 294 mẫu offline và 349 mẫu live cluster
TC4	Phục vụ đồng thời ≥ 5 đề án	ĐẠT	8 Virtual Key (7 đề án + 1 pilot) qua LiteLLM Gateway, RBAC, hạn mức \$10,0/đề án
CD	CD tự động, phục vụ đa mô hình	ĐẠT	Argo CD App-of-Apps điều phối Qwen2.5-7B và Qwen2.5-1.5B trên cụm 4 node GPU

1. Hạ tầng GitOps và cơ chế CD khi rollout mô hình mới

Tệp `deploy/state.yaml` trong Git là nguồn sự thật duy nhất. Argo CD phát hiện thay đổi và đồng bộ trạng thái xuống cụm Kubernetes (auto sync bật).

1.1. Chu trình rollout


1 · idle Bản stable nhận 100% traffic.	2 · evaluating Ứng viên chạy ở endpoint nội bộ riêng; test độc lập về chất lượng, Guardrail, latency. Không đạt thì hủy, về idle.	3 · canary Cấp 10–25% traffic thật cho ứng viên.	4 · promoting Ứng viên thành stable; Argo CD rolling update thay bản cũ.	5 · watching Hậu kiểm theo chỉ số; sẵn sàng rollback về bản trước.
--	---	--	--	--

1.2. Model Contract


- **Định dạng:** chỉ nhận safetensors; từ chối Torch Pickle (.bin, .pt, .ckpt).
- **Toàn vẹn:** manifest.json chứa SHA-256 từng tệp, ký bằng AWS KMS (ECC P-256).
- **Xác thực lúc nạp:** Init Container tính lại SHA-256 trên NVMe cục bộ của GPU node trước khi giao cho vLLM; sai lệch thì không khởi động.

1.3. Đa mô hình trên cụm


Ứng dụng root (path deploy/argocd/apps) quản lý 2 ứng dụng con trỏ vào charts/vllm, namespace inference: vllm-qwen2-5-7b-stable và vllm-qwen2-5-1-5b-stable. Cả 3 ứng dụng ở trạng thái Healthy và Synced to main (62142f8).




Hình 1. Argo CD, danh sách ứng dụng: root, vllm-qwen2-5-1-5b-stable, vllm-qwen2-5-7b-stable đều Healthy / Synced / Sync OK, target revision main.



Hình 2. Cây ứng dụng `root` (App-of-Apps): đồng bộ xuống 2 ứng dụng con của 2 mô hình. Last sync OK, auto sync enabled.



Hình 3. `vllm-qwen2-5-1-5b-stable` : Service, Deployment (rev:2), ReplicaSet và Pod 1/1 running, Healthy.



Hình 4. `vllm-qwen2-5-7b-stable` : cùng cấu trúc, Pod 1/1 running, Healthy, Sync OK tới 62142f8.

2. Gateway quản lý đa đề án (TC4 – LiteLLM)


- **Quản trị tập trung:** LiteLLM Dashboard (`/ui`, v1.90.2) liệt kê, tạo và thu hồi Virtual Key.
- **8 Virtual Key:** `da19`, `da20`, `da32`, `da39`, `da41`, `da44`, `da45` và `moc-da-pilot`; tất cả Active, thuộc Team `moc-shared`.
- **RBAC:** mỗi key chỉ gọi được `qwen2.5-7b` và `qwen2.5-1.5b`.
- **Ngân sách:** \$10,0 cho mỗi đề án, cách ly chi tiêu giữa các nhóm.
- **Lưu trữ khóa:** LiteLLM chỉ giữ bản hash; chuỗi `sk-...` bản rõ nằm trong Kubernetes Secret `llm-serving/agent-keys` phục vụ bàn giao.

Key ID	Key Alias	Status	Secret Key	Team	Organization	User	Created At	Created By	Updated At	Last Active	Expires At
b475ef371b...	moc-da-pilot	Active	sk-...AyoA	moc-shared	-	moc-da-pilot	9/10/2026	Default Proxy Admin	9/10/2026	Unknown	Never
ebb63846d6...	da45	Active	sk-...Jc7g	moc-shared	-	da45	9/10/2026	Default Proxy Admin	9/10/2026	Unknown	Never
573ef17d28...	da44	Active	sk-...QMPq	moc-shared	-	da44	9/10/2026	Default Proxy Admin	9/10/2026	Unknown	Never
2ff76157ce...	da41	Active	sk-...yvWk	moc-shared	-	da41	9/10/2026	Default Proxy Admin	9/10/2026	Unknown	Never
cfcc41b28b...	da39	Active	sk-...PDlg	moc-shared	-	da39	9/10/2026	Default Proxy Admin	9/10/2026	Unknown	Never
deb1a8098b...	da32	Active	sk-...6b8w	moc-shared	-	da32	9/10/2026	Default Proxy Admin	9/10/2026	Unknown	Never


Hình 5. LiteLLM, Virtual Keys: "Showing 1 – 8 of 8 results". Khung chụp hiển thị 6 key đầu (moc-da-pilot , da45 , da44 , da41 , da39 , da32), trạng thái Active, Team moc-shared . Cột model và budget nằm ngoài khung chụp.

3. Giao diện chatbot nghiệp vụ (Open WebUI – MOC Copilot)


- **Người dùng:** chuyên viên phân tích GreenSM. Kết nối LiteLLM bằng tài khoản moc-da-pilot .
- **Chọn mô hình:** dropdown chuyển giữa qwen2.5-7b (tác vụ phức tạp) và qwen2.5-1.5b (tác vụ đơn giản).
- **Khởi tạo admin:** hook lifecycle.postStart trong Helm chart tạo tài khoản admin@da51.lab từ Secret khi pod khởi động; đăng nhập trực tiếp, không qua màn hình setup.
- **Guardrail:** tắt các tác vụ nền tự sinh (tiêu đề, tag, gợi ý câu hỏi) để log kiểm toán của pipeline Guardrail chỉ gồm câu hỏi người dùng.



Hình 6. Dropdown chọn mô hình: qwen2.5-7b , qwen2.5-1.5b .



Hình 7. Qwen2.5-7B: câu hỏi về định nghĩa chỉ số và grain bảng đặt chuyến; câu trả lời kèm mã trích dẫn [METRIC-...] .



Hình 8. Qwen2.5-1.5B: câu hỏi kiểm tra dữ liệu và trạm sạc; câu trả lời kèm mã [KB-FRESHNESS] , [METRIC-CHARGE-001] .

4. Năng lực serving và benchmark (TC1a, TC1b, TC3)

Cấu hình đo: ramp 30 phút, 8 mức tải từ 1 đến 50 req/s, tổng 34.354 probe request; 4x NVIDIA A10G (EC2 g5.xlarge); Semantic Cache tắt để đo sức tải thật của engine và Guardrail.

Tải (req/s)	Request	p50 (ms)	p95 (ms)	p99 (ms)	Availability	TC1a
1	171	587	1.036	1.444	100,00%	Đạt
10	1.700	563	1.082	2.007	99,94%	Đạt
20	3.388	540	1.881	6.522	99,71%	Đạt
30	5.086	556	1.180	1.827	99,71%	Đạt
40	6.787	629	1.660	5.412	99,81%	Đạt
45	7.631	641	1.466	2.450	99,74%	Đạt
50	8.486	694	1.590	2.549	99,82%	ĐẠT

- **TC1a:** p95 tại 50 req/s là 1.590 ms, thấp hơn ngưỡng 3.000 ms.
- **TC1b:** availability 99,7228% (cận dưới một phía 95% CI, 34.354 probe), vượt ngưỡng 99,5%. Toàn bộ request bị từ chối (0,23%) do Guardrail grounding chặn đúng quy tắc; không có 5xx hoặc timeout.
- **TC3:** chặn 100% mẫu tấn công jailbreak / prompt injection, chặn nhầm 0% trên 294 mẫu offline và 349 mẫu live cluster.

p99 tại 20 và 40 req/s tăng đột biến (6.522 ms, 5.412 ms) trong khi p95 vẫn dưới ngưỡng. Chưa có tiêu chí p99; sẽ kiểm tra đuôi latency ở tuần 5.

5. FinOps và tối ưu TCO (TC2)

5.1. Chi phí AWS thực tế

Tổng chi phí 01/09 – 06/10/2026: **\$86,79** (usage thực tế trước credit, toàn tài khoản). Đơn giá đối soát từ hóa đơn: g5.xlarge (A10G) \$1,006/giờ; g6.xlarge (L4) \$0,8048/giờ; m7i.large \$0,1008/giờ. Chi tiết: reports/aws-continuous-cost-2026-10-07.md .

5.2. TCO production 24/7 tại 10 req/s

Cấu hình tham chiếu P2 (Multi-AZ): 2 GPU L4, 4 CPU node, Aurora Multi-AZ, Redis HA; chi phí cố định \$2.263,01/tháng. Chi tiết: reports/production-cost-estimation-tco-2026-10-05.md .

Phương án	\$/ngày	\$/tháng (30 ngày)	Chênh lệch
Tự host Qwen 7B (P2)	76,47	2.294,01	Mốc so sánh
Qwen2.5-7B qua Cloud API (Phala)	167,24	5.017,28	Tự host rẻ hơn 54,3%
GPT-4o mini (OpenAI)	233,49	7.004,67	Tự host rẻ hơn 67,2%
Gemini 3.5 Flash-Lite (Google)	480,08	14.402,46	Tự host rẻ hơn 84,1%

Điểm hòa vốn: 3,00 – 3,43 req/s (~259.000 request/ngày). Từ 10 req/s trở lên, tự host tiết kiệm 49,4% – 54,3%, so với yêu cầu 30% của TC2.

6. Kế hoạch Tuần 5

Phụ trách	Hạng mục
Nguyễn Gia Bảo	- Kết hợp tầng CI với nhóm Deployment Quality Gate: quét image (Trivy), kiểm tra manifest (Conftest), ký image (Cosign), policy Kyverno ML-001 . - Soạn tài liệu đặc tả kiến trúc kỹ thuật: Serving, pipeline Guardrail, GitOps CD, Model Contract.
Nguyễn Lê Minh	- Tài liệu bàn giao và tích hợp cho các nhóm đề án: API Reference, mẫu code (Python, cURL, LangChain), quy trình cấp và quản lý Virtual Key. - Runbook vận hành: giám sát Grafana, vận hành cụm vLLM đa mô hình, sao lưu và phục hồi.

Ngân sách: chi tiêu lũy kế \$86,79 / \$200,00 AWS được cấp. Duy trì bật/tắt cụm GPU theo lịch làm việc.